1. Objetivo de la estrategia

El ecosistema fue diseñado para que la Inteligencia Artificial intervenga únicamente en las etapas en las que aporta valor real. Las operaciones determinísticas, como cálculos presupuestarios, validaciones de estados y control de duplicados, se resuelven mediante Airtable y Make. Esto evita consumir tokens de IA en tareas que pueden resolverse con reglas exactas y reproducibles.

El prototipo académico utiliza Cohere para las tareas de interpretación y generación de texto debido a restricciones presupuestarias durante el desarrollo. Para una implementación productiva alineada con la arquitectura propuesta por el curso, se plantea una estrategia en la que las tareas estructuradas puedan ejecutarse con un modelo económico de OpenAI y los análisis de contexto extenso puedan delegarse a Claude. La sustitución del proveedor de IA no modifica la arquitectura general del sistema, ya que el intercambio entre módulos se encuentra estructurado mediante variables dinámicas y JSON.

2. Matriz analítica de ahorro

Para evaluar el impacto económico de una eventual implementación a escala se reutiliza el escenario desarrollado en la Pre-Entrega 6, compuesto por 500 solicitudes presupuestarias.

Estrategia	Costo relativo simulado	Costo simulado (500 solicitudes)	Ahorro estimado
Procesamiento estándar	100%	USD 150	0%
Message Batches API	50%	USD 75	50%
Batch + Prompt Caching	~15% - 20%	USD 22,50 - 30	~80% - 85%

3.1 Supuesto matemático

Escenario estándar: 500 solicitudes x USD 0,30 de costo medio simulado por solicitud = USD 150.

Con procesamiento Batch: USD 150 x 50% = USD 75.

Ahorro directo: USD 150 - USD 75 = USD 75, equivalente a un 50% de ahorro.

En la simulación desarrollada previamente, la combinación de Batch + Prompt Caching reduce el costo estimado hasta aproximadamente USD 22,50-30, equivalente a un ahorro total aproximado de USD 120-127,50 respecto del escenario estándar.

3. Aplicación del procesamiento Batch

Batch no se propone para el flujo principal operativo, porque una solicitud que llega por Gmail debe ser procesada y puesta a disposición del responsable humano en un plazo razonablemente corto. Introducir procesamiento diferido en ese punto degradaría la experiencia y retrasaría la aprobación.

Sí resulta adecuado para extensiones del sistema orientadas a análisis masivos no urgentes, por ejemplo:

1. Airtable acumula durante la semana solicitudes ya procesadas.
2. Make agrupa los registros que deben analizarse de forma masiva.
3. Se genera un lote con una entrada por solicitud.
4. El proveedor procesa el lote de forma asíncrona.
5. Los resultados consolidados alimentan un reporte periódico de FP&A.

Entre los casos de uso posibles se incluyen análisis de tendencias presupuestarias, detección de centros de costos con sobre-ejecución, clasificación de motivos de solicitud y generación de reportes consolidados.

4. Aplicación de Prompt Caching

En una versión productiva más avanzada podría existir un bloque corporativo estable que se reutilice en cada solicitud. Ese prefijo contendría información que cambia poco o nada entre ejecuciones.

- Políticas de asignación presupuestaria.
- Definición y uso de centros de costos.
- Límites y reglas de aprobación.
- Criterios para cubrir brechas presupuestarias.
- Casos que requieren escalamiento o revisión humana.
- Formato obligatorio de respuesta y reglas de no invención de datos.

Las variables dinámicas quedarían fuera de ese bloque estático y cambiarían en cada ejecución, por ejemplo: centro_costos, monto_solicitado, motivo y presupuesto_disponible.

En la Pre-Entrega 6 se modeló un prefijo estático aproximado de 6.000 tokens. Mantener ese bloque idéntico entre ejecuciones permite reducir el procesamiento repetido del mismo contexto y combinar esta optimización con procesamiento Batch en tareas masivas.

5. Flexibilidad del proveedor de IA

La implementación actual utiliza la IA de Cohere. Esta elección responde a la necesidad de construir y probar el prototipo con una alternativa accesible durante el desarrollo. Sin embargo, la arquitectura desacopla los módulos de IA del resto del ecosistema.

Por lo tanto, reemplazar Cohere por OpenAI o Claude no exige rediseñar Gmail, los parsers JSON, Airtable, los Routers, el Human-in-the-Loop, Slack, el Dashboard ni el escenario de comunicación final. El cambio queda concentrado en los módulos de IA y en el formato específico de la llamada al proveedor.